

선형대수학팀

3팀

김다민
이지원
조성우
김수인
방건우

이번 주 예고

이번 주
예고입니다



이번 주 예고

1. 행렬식, 노름, 내적, 직교성

2. 정사영과 회귀

3. 평균, 분산, 상관계수의

기하학적 해석

4. 고유값과 고유 벡터

5. 특이값 분해

1

행렬식, 노름, 내적, 직교성

행렬식 *Determinant*

행렬식 *Determinant*

$n \times n$ 정방행렬에 스칼라를 대응시키는 함수이며 $\det(A)$ 라고 표현

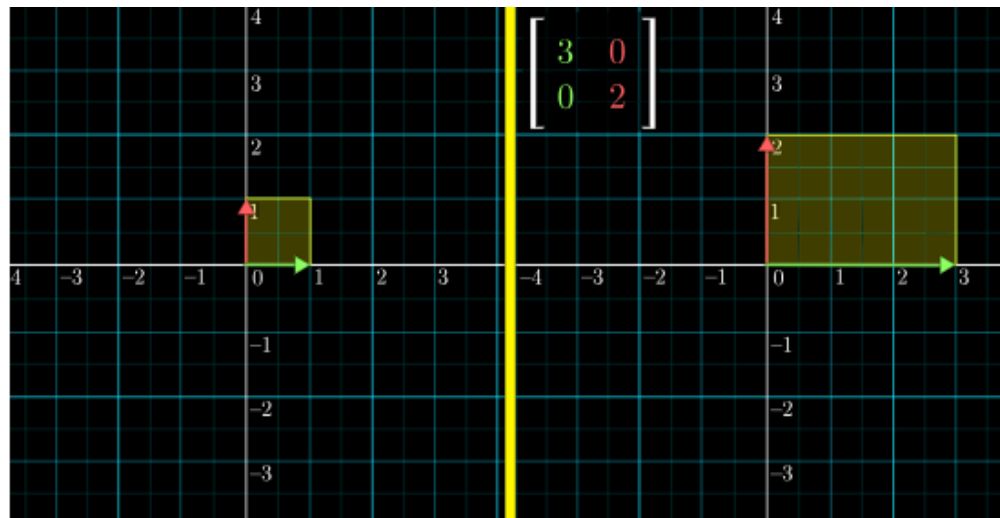
$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \text{ 일 때, 행렬식은 } \det(A) = ad - cb$$

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \text{ 일 때, 행렬식은 여인수분해를 통해 계산}$$

행렬식 *Determinant*


행렬식의 기하학적 해석

선형 변환을 할 때 선형 변환이 공간을 얼마나 변환시키는지
행렬식을 통해 알 수 있음




EX) 기저벡터 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 에 행렬 $A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}$ 을 통한 선형변환

행렬식 *Determinant*



선형변환 전 넓이 = 1

기저벡터 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}$




선형변환 후 넓이 = 6

기저벡터 $\begin{bmatrix} 3 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 2 \end{bmatrix}$

$$\det(A) = \begin{vmatrix} 3 & 0 \\ 0 & 2 \end{vmatrix} = 6$$


선형변환 후 평행사변형의 넓이

행렬식 *Determinant*



선형변환 전 넓이 = 1

기저벡터 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}$



선형변환 후 넓이 = 6


기저벡터 $\begin{bmatrix} 3 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 2 \end{bmatrix}$

행렬식은 2차원 실수 공간 \mathbb{R}^2 에서는 넓이
3차원 실수 공간 \mathbb{R}^3 에서는 부피와 관련있음

행렬식 *Determinant*

행렬식의 부호

행렬식이 음수인 경우 **공간이 뒤집힌 경우**를 의미



좌측 선형변환

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, \det(A) = 4$$

우측 선형변환


$$A = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}, \det(A) = -4$$

면적은 같지만 좌우반전된 상태

행렬식 *Determinant*

행렬식의 부호

행렬식이 음수인 경우 **공간이 뒤집힌 경우**를 의미



좌측 선형변환

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, \det(A) = 4$$



우측 선형변환

$$A = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}, \det(A) = -4$$

행렬식의 부호 = 공간의 **반전** 상태

면적은 같지만 좌우반전된 상태

행렬식 *Determinant*



행렬식이 0인 것의 의미

$\det(A) = 0$ 이면 행렬의 넓이나 부피가 없음

행렬 A 가 **공간을 압축하는 선형변환**임을 의미

$$\det \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} = 0$$

$0 \cdot A$



행렬식 *Determinant*

행렬식의 쓰임

행렬식을 통해 역행렬의 존재 유무 판단



역행렬이 존재

$= Ax = b$ 가 유일한 해를 갖는다.

$= x$ 와 Ax 가 서로 일대일 대응이다.

공간이 압축되는 선형변환의 경우, 역행렬이 존재하지 않음

선형대수학팀 1주차 클린업 복습

행렬식 *Determinant*

행렬식의 쓰임

행렬식을 통해 역행렬의 존재 유무 판단



역행렬이 존재

$\leftrightarrow Ax = b$ 가 유일한 해를 갖는다.

$\leftrightarrow x$ 와 Ax 가 서로 일대일 대응이다.

공간이 압축되는 선형변환의 경우, 역행렬이 존재하지 않음

선형대수학팀 1주차 클린업 복습



행렬식 *Determinant*

행렬식의 쓰임

행렬식을 통해 역행렬의 존재 유무 판단

$\det(A) = 0$ 인 경우 행렬 A 는 공간을 압축시키는 선형변환



이때, 행렬 A 의 역행렬은 존재하지 않음

$= Ax = b$ 가 유일한 해를 갖는다.

$= x$ 와 Ax 가 서로 일대일 대응이다.

공간이 압축되는 선형변환의 경우, 역행렬이 존재하지 않음

선형대수학팀 1주차 클린업 복습



노름 *Norm*

노름 *Norm*

노름은 벡터의 크기를 의미
거리와 유사한 개념으로 이해


$$\|v\|_p = Lp = \sqrt[p]{|v_1|^p + |v_2|^p + \cdots + |v_n|^p}$$

통계에서는 $P=1$ 인 L_1 Norm과 $P=2$ 인 L_2 Norm을 주로 사용

노름 *Norm*

맨해튼 노름 *L1 norm*

각 벡터들의 절댓값을 합한 결과
직선이 아닌 좌표축을 따라 움직이는 거리




$$L_1 = |v_1| + |v_2| + \dots + |v_n|$$

그림에서
빨간색, 파란색, 노란색 선으로 표현가능


노름 Norm

맨해튼 노름 $L1\ norm$

각 벡터들의 절댓값을 합한 결과
직선이 아닌 좌표축을 따라 움직이는 거리



Lasso regression에서 β 의 제약조건으로 쓰임




그림에서 빨간색, 파란색, 노란색 선으로 표현가능.

노름 *Norm*

유클리드 노름 *L2 norm*

원점에서 벡터에 연결된 직선거리

좌표평면에서의 점과 점 사이의 거리



$$L_2 = \sqrt{|v_1|^2 + |v_2|^2 + \dots + |v_n|^2}$$


그림에서 초록색 선으로 표현가능

노름 *Norm*


유클리드 노름 *L2 norm*

원점에서 벡터에 연결된 직선거리

좌표평면에서의 점과 점 사이의 거리



Ridge regression에서 β 의 제약조건으로 쓰임



노름 *Norm*



유클리드 노름 $L2\ norm$

원점에서 벡터까지의 직선거리

좌표평면에서의 점과 점 사이의 거리


L1, L2 Norm은 주로 머신러닝에서 제약조건을 설정할 때 많이 사용

EX) L1 regularization, L2 regularization

Ridge regression에서 β 의 제약조건으로 쓰임

L^2 -norm

Ridge & Lasso에 대해 궁금하다면 회귀팀 클린업 많관부



내적 *Inner product*

내적 *Inner product*

벡터를 곱하는 방법

벡터의 내적 결과값은 스칼라

내적의 특징과 식

when $x = 0$ or $y = 0, x \cdot y = 0$

$$x \cdot y = \|x\| \times \|y\| \times \cos\theta$$

$$x \cdot x = \|x\| \times \|x\| \times \cos 0 = \|x\|^2$$

$$\text{when } x = (x_1, x_2, \dots, x_n), \|x\|^2 = \sum_{i=1}^n x_i^2$$

내적 *Inner product*

내적 *Inner product*

벡터를 곱하는 방법

벡터의 내적 결과값은 스칼라



내적의 특징과 식

① *when* $\mathbf{x} = 0$ or $\mathbf{y} = 0$, $\mathbf{x} \cdot \mathbf{y} = 0$

② $\mathbf{x} \cdot \mathbf{y} = \|\mathbf{x}\| \times \|\mathbf{y}\| \times \cos\theta$

③ $\mathbf{x} \cdot \mathbf{x} = \|\mathbf{x}\| \times \|\mathbf{x}\| \times \cos 0 = \|\mathbf{x}\|^2$


④ *when* $\mathbf{x} = (x_1, x_2, \dots, x_n)$, $\|\mathbf{x}\|^2 = \sum_{i=1}^n x_i^2$

내적 *Inner product*

내적의 기하학적 의미

길이 \times 길이 \times 두 벡터가 이루는 코사인 사잇각

$$\mathbf{x} \cdot \mathbf{y} = \|\mathbf{x}\| \times \|\mathbf{y}\| \times \cos\theta$$



$|x|\cos\theta$ 는 벡터 \mathbf{y} 와 평행하고 벡터 \mathbf{x} 에서 벡터 \mathbf{y} 로
수직을 이루는 삼각형의 밑변




해당 밑변의 길이에 $|\mathbf{y}|$ 를 곱하면 내적

내적 *Inner product*

내적의 기하학적 의미

길이 \times 길이 \times 두 벡터가 이루는 코사인 사잇각

$$\mathbf{x} \cdot \mathbf{y} = \|\mathbf{x}\| \times \|\mathbf{y}\| \times \cos\theta$$



$|\mathbf{x}| \cos \theta$ 는 벡터 \mathbf{x} 에서
벡터 \mathbf{y} 로 수직을 이루는 삼각형의 밑변의 길이




해당 밑변의 길이에 $|\mathbf{y}|$ 를 곱하면 내적

직교성 *Orthogonality*

직교성 *Orthogonality*

두 벡터가 수직일때, 두 벡터가 직교한다고 표현



두 벡터가 수직이면 사잇값 θ 는 $\pi/2$

$$\mathbf{x} \cdot \mathbf{y} = \|\mathbf{x}\| \times \|\mathbf{y}\| \times \cos\left(\frac{\pi}{2}\right) = 0$$



두 벡터가 직교하면 $\mathbf{x} \cdot \mathbf{y} = 0$

직교성 *Orthogonality*

직교성 *Orthogonality*

두 벡터가 수직일때, 두 벡터가 직교한다고 표현



임의의 벡터 u 와 영벡터는 직교할까?

두 벡터를 내적했을 때 내적값이 0이면 두 벡터는 직교

어떤 벡터든 영벡터와 내적하면 0이 됨

⋮

임의의 벡터 u 와 영벡터는 항상 직교

직교성 *Orthogonality*

정규직교성 *Orthonormality*

두 벡터의 노름이 모두 1이면서 서로 직교하는 상황을 의미
노름이 1이기 때문에 오로지 방향 성분만을 나타냄



정규직교 조건

두 벡터 x, y 가 orthonormal

\vdots

① $x \cdot y = 0$

② $\|x\| = \|y\| = 1$




직교성 *Orthogonality*

공간의 직교성 *Orthogonality of space*

어떤 공간 S 와 부분공간 T 가 직교

\leftrightarrow

공간 S 안에 있는 모든 벡터가 부분공간 T 안에 있는 모든 벡터와 직교




직교성 *Orthogonality*

공간의 직교성 *Orthogonality of space*

어떤 공간 S 와 부분공간 T 가 직교

\leftrightarrow

공간 S 안에 있는 모든 벡터가 부분공간 T 안에 있는 모든 벡터와 직교



두 subspace가 직교

:

초록 평면에 존재하는 모든 벡터가
파란색 선 내의 벡터와 직교

직교성 *Orthogonality*

직교행렬 *Orthogonal Matrix*

행벡터와 열벡터가 유클리드 공간의 정규 직교 기저를 이루는 실수 행렬

$$Q^{-1} = Q^T \text{ or } QQ^T = Q^T Q = I$$



직교행렬의 성질

① 직교행렬의 전치행렬은 직교행렬

② 직교행렬의 곱은 직교행렬

③ 만약 Q 가 직교행렬이라면 Q 의 행렬식은 1 또는 -1
(공간의 크기가 유지)

④ 직교행렬 Q 는 회전을 하는 선형변환

직교성 *Orthogonality*

직교행렬 *Orthogonal Matrix*

행벡터와 열벡터가 유클리드 공간의 정규 직교 기저를 이루는 실수 행렬

$$Q^{-1} = Q^T \text{ or } QQ^T = Q^T Q = I$$



직교행렬의 성질

① 직교행렬의 전치행렬은 직교행렬

② 직교행렬의 곱은 직교행렬

③ 만약 Q 가 직교행렬이라면 Q 의 행렬식은 1 또는 -1
(공간의 크기가 유지)

④ 직교행렬 Q 는 **회전**을 하는 선형변환

2

정사영과 회귀

정사영과 회귀

$$\text{Let } X = [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_p]$$

$$\text{then } X\beta = [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_p] \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} = \mathbf{y}$$



$Ax = b$ 문제는 회귀문제 $X\beta = y$ 로 생각 가능

행렬 A : 독립변수들의 집합 X

벡터 b : 종속변수 y

해 x : 회귀계수 β

정사영과 회귀

X 의 각 열은 각각의 변수를 의미하므로
 $X\beta$ 는 열벡터의 선형결합으로 y 를 표현 가능케 하는 β 를 찾는 문제



1주차 Remark 행렬에 벡터를 곱한 것은 열벡터의 선형결합

X 의 열공간 내에 y 가 존재한다
 $\Leftrightarrow X$ 의 열벡터의 선형결합으로 y 를 완벽하게 재현할 수 있다

정사영과 회귀



1주차 Remark



행렬에 벡터를 곱한 것은 열벡터의 선형결합

그러나, 현실에서는 X 로 y 를 예측하고자 할 때 **오차** 발생

이때 **오차를 최소화**하는 방향으로 분석 진행

$X\beta$ 는 열벡터의 선형결합으로 y 를 표현 가능케 하는 β 를 찾는 문제




X 의 열 벡터를 **정사영**을 이용! 재현한다

↔ X 의 열벡터의 선형결합으로 y 를 완벽하게 재현할 수 있다

정사영 *Orthogonal Projection*

투영 *Projection*

어떤 벡터를 다른 벡터로 옮겨서 표현하는 것이며,
 벡터 b 의 공간으로 여분의 공간을 압축시키는 **선형변환**의 일종




노란색 방향으로 모두
 Projection 가능

정사영 *Orthogonal Projection*

정사영 *Orthogonal Projection*

벡터를 다른 벡터로 투영시킬 때는 여러 각도로 투영 가능
그 중 정사영은 직각을 이루어 투영시키는 것



벡터 a_1 은 벡터 b 에 대해
Orthogonal Projection




정사영 *Orthogonal Projection*

왜 직각인가?

정사영 *Orthogonal Projection*

벡터를 다른 벡터로 투영시킬 때는 여러 각도로 투영 가능

벡터 a 를 투영시키면 원래 벡터와의 차이 a_2 발생



실제 값과 투영 이후의 차이를 오차라고 하면

수직으로 내리는 정사영 벡터가 오차를 최소가 되게 함


Orthogonal Projection

정사영 *Orthogonal Projection*

Vector Projection 구하기



b 를 a 에 정사영시키는 문제를 통해 Vector Projection 계산 방법을 알아보자



정사영된 벡터 $\mathbf{x} = p\mathbf{a}$ 에 대해, 편차벡터 $\mathbf{b} - p\mathbf{a}$ 는 벡터 \mathbf{a} 와 수직이므로 **내적이 0**

이를 이용하여 벡터 \mathbf{x} 를 구할 수 있음


$$\mathbf{b}^T \mathbf{a} - p \mathbf{a}^T \mathbf{a} = 0$$

$$p = \frac{\mathbf{b}^T \mathbf{a}}{\mathbf{a}^T \mathbf{a}} \quad \therefore \mathbf{x} = p\mathbf{a} = \frac{\mathbf{b}^T \mathbf{a}}{\mathbf{a}^T \mathbf{a}} \mathbf{a}$$

정사영 *Orthogonal Projection*

정사영: 벡터 \rightarrow 공간

정사영의 목적은 높은 차원의 부분공간에 속한 벡터를 **저차원으로 낮추는 것**으로
3차원 공간에 있는 벡터를 2차원 벡터로 바꾸어 표현하는 방식



$\text{col}(A)$ 는 A 의 열 공간으로,
오차 $\mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - X\hat{\beta}$ 가 최소화되도록
근사한 점이 $\hat{\mathbf{b}}$

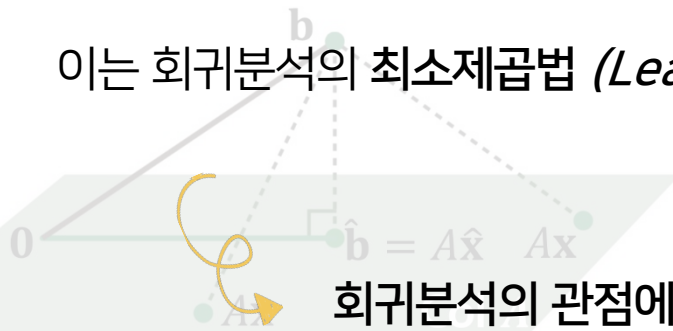
정사영 *Orthogonal Projection*

정사영: 벡터 \rightarrow 공간

정사영의 목적은 높은 차원의 부분공간에 속한 벡터를 **저차원으로 낮추는** 것으로
3차원 공간에 있는 벡터를 2차원으로 바꾸어 표현하는 방식



이는 회귀분석의 **최소제곱법 (Least Square Method)**에서 사용




오차 $\mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - X\hat{\beta}$ 가 최소화되도록

회귀분석의 관점에서 정사영을 이해해보자!

최소제곱법과 정사영



모든 데이터를 통과하는 직선을 구하는 것이 이상적인 목표
= 연립방정식의 해를 구하는 것이 **선형대수**의 목표



현실에서 모든 점을 통과하는 직선은 불가능

이는 $X\beta = y$ 에서 **벡터 y 가 행렬 X 의 열공간에 존재하지 않음**을 의미

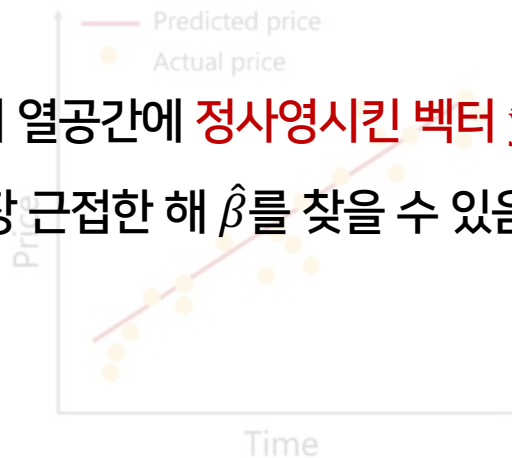
최소제곱법과 정사영



모든 데이터를 통과하는 직선을 구하는 것이 이상적인 목표
= 연립방정식의 해를 구하는 것이 **선형대수**의 목표



y 벡터를 X 의 열공간에 **정사영시킨 벡터 \hat{y}** 를 구하면
가장 근접한 해 $\hat{\beta}$ 를 찾을 수 있음!



현실에서 모든 점을 통과하는 직선은 불가능

이는 $X\beta = y$ 에서 **벡터 y** 가 **행렬 X 의 열공간에 존재하지 않음**을 의미

최소제곱법과 정사영



모든 데이터를 통과하는 직선을 구하는 것이 이상적인 목표

= 연립방정식 정리하자면



y 벡터를 X 의 열공간에 정사영시킨 벡터 \hat{y} 를 구하면



설명 불가능한 벡터 y 를 X 의 열공간에 정사영시키기



실제 해 β 가 아닌 추정치 $\hat{\beta}$ 를 구하기

이는 $X\beta = y$ 에서 벡터 y 가 행렬 X 의 열공간에 존재하지 않음을 의미

최소제곱법과 정사영

$$\text{편차벡터 } e = y - \hat{y} = y - X\hat{\beta}$$


편차벡터와 X 의 열공간은 수직이므로 다음 식이 성립

$$X^T(\mathbf{y} - X\hat{\beta}) = 0$$

$$X^T \mathbf{y} = X^T X \hat{\beta}$$

$$(X^T X)^{-1} X^T \mathbf{y} = \hat{\beta}$$

$$\therefore X(X^T X)^{-1} X^T \mathbf{y} = X\hat{\beta} = \hat{\mathbf{y}}$$



최소제곱법과 정사영

$$\text{편차벡터 } e = y - \hat{y} = y - X\hat{\beta}$$

편차벡터와 X 의 열공간은 수직이므로 다음 식이 성립


$$X^T(y - X\hat{\beta}) = 0$$

$$X^T y = X^T X \hat{\beta}$$

$$(X^T X)^{-1} X^T y = \hat{\beta}$$

$$\therefore X(X^T X)^{-1} X^T y = X\hat{\beta} = \hat{y}$$


정사영행렬 *projection matrix* 또는 모자행렬 *hat matrix*



최소제곱법과 정사영

미분을 통한 최소제곱법 풀이



1주차에 배웠던 행렬 미분을 통해서도 최소제곱법 해결 가능! 

오차를 최소화하는 β 를 찾기 위해 식을 다음과 같이 전개

$$\begin{aligned}\hat{\beta} &= \arg \min_{\beta} \|\mathbf{y} - X\beta\| = \arg \min_{\beta} \|\mathbf{y} - X\beta\|^2 = \arg \min_{\beta} (\mathbf{y} - X\beta)^T (\mathbf{y} - X\beta) \\ &= \arg \min_{\beta} \mathbf{y}^T \mathbf{y} - \mathbf{y}^T X\beta - \beta^T X^T \mathbf{y} + \beta^T X^T X\beta\end{aligned}$$



β 로 미분한 값이 0이 되는 β 를 찾아보자!

최소제곱법과 정사영

미분을 통한 최소제곱법 풀이

미분대상 $y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta$ 이 스칼라이므로
스칼라를 벡터로 미분하는 경우에 해당

$$-X^T y - X^T y + X^T X\beta + X^T X\beta = 2X^T X\beta - 2X^T y = 0$$

$$\Rightarrow X^T X\beta = X^T y$$

$$\Leftrightarrow \beta = X(X^T X)^{-1} X^T y$$



따라서 오차의 길이가 최소가 되는 $\hat{\beta}$ 역시 $X(X^T X)^{-1} X^T y$ 가 됨

3

평균, 분산, 상관계수의
기하학적 해석

표본평균의 기하학적 해석

표본평균 유도 과정

① $n \times 1$ 인 벡터 $\mathbf{1}_n^T = \mathbf{1}^T = [1, \dots, 1]$ 을 정의하고크기를 1로 만들어 단위벡터 $(\frac{1}{\sqrt{n}})\mathbf{1}$ 정의② i 번째 변수인 열벡터 $\mathbf{x}_i^T = [x_{1i}, x_{2i}, \dots, x_{ni}]$ 생각③ 단위벡터 $(\frac{1}{\sqrt{n}})\mathbf{1}$ 에 \mathbf{x}_i 를 투영시키기

$$\mathbf{x}_i^T \left(\frac{1}{\sqrt{n}} \mathbf{1} \right) \frac{1}{\sqrt{n}} \mathbf{1} = \frac{x_{1i} + x_{2i} + \dots + x_{ni}}{n} \mathbf{1} = \bar{x}_i \mathbf{1} \quad \text{---} \rightarrow \text{표본평균벡터}$$

✓ 결론 \mathbf{x}_i 변수의 표본평균은 해당 열벡터를 단위벡터에 투영시킨 결과

표본분산의 기하학적 해석

✓ 편차 벡터 *Deviation Vector, Mean centered vector*


편차 벡터 \mathbf{d}_i 는 다음과 같으며,
 \mathbf{d}_i 의 각 원소는 각 관찰값의 i 번째 변수들의 편차와 같음

$$\mathbf{d}_i = \mathbf{x}_i - \bar{x}_i \mathbf{1} = \begin{bmatrix} x_{1i} - \bar{x}_i \\ x_{2i} - \bar{x}_i \\ \vdots \\ x_{ni} - \bar{x}_i \end{bmatrix}$$



표본분산의 기하학적 해석

표본분산과 편차 벡터의 관계



편차 벡터의 길이를 제곱(내적)한 값을 살펴보면

$$L_{d_i}^2 = d_i^T d_i = \sum_{j=1}^n (x_{ji} - \bar{x}_i)^2 = S_{x_i x_i}$$



편차 벡터의 길이 제곱은 편차 제곱의 합과 동일하며,
이를 $n - 1$ 로 나누어 주면 **i 번째 변수의 표본 분산**이 됨
따라서, 표본분산은 편차 벡터 길이 제곱에 **비례**

상관계수의 기하학적 해석

두 벡터 $\mathbf{x} = [x_1, x_2 \cdots, x_n]^T, \mathbf{y} = [y_1, y_2 \cdots, y_n]^T$ 를 생각해보자!



두 편차 벡터 d_x 와 d_y 에 대해 다음 식 성립

$$d_x^T d_y = \sum_{j=1}^n (x_i - \bar{x})(y_i - \bar{y}) = S_{xy}$$



내적의 정의에 의해 $d_x^T d_y = L_{d_x} L_{d_y} \cos \theta$

θ 는 \mathbf{x} 와 \mathbf{y} 의 편차 벡터가 이루는 각도



$$S_{xy} = d_x^T d_y = \sqrt{S_{xx}} \sqrt{S_{yy}} \cos \theta$$

$$\therefore \cos \theta = \frac{S_{xy}}{\sqrt{S_{xx}} \sqrt{S_{yy}}} = r_{xy}$$



결론적으로 두 편차 벡터 사이의 각도가 상관계수를 결정

상관계수의 기하학적 해석

두 벡터 $\mathbf{x} = [x_1, x_2 \cdots, x_n]^T, \mathbf{y} = [y_1, y_2 \cdots, y_n]^T$ 를 생각해보자!




두 편차 벡터 d_x 와 d_y 에 대해 다음 식 성립

$$d_x^T d_y = \sum_{j=1}^n (x_i - \bar{x})(y_i - \bar{y}) = S_{xy}$$



내적의 정의에 의해 $d_x^T d_y = L_{d_x} L_{d_y} \cos \theta$

θ 는 \mathbf{x} 와 \mathbf{y} 의 편차 벡터가 이루는 각도



$$S_{xy} = d_x^T d_y = \sqrt{S_{xx}} \sqrt{S_{yy}} \cos \theta$$

$$\therefore \cos \theta = \frac{S_{xy}}{\sqrt{S_{xx}} \sqrt{S_{yy}}} = r_{xy}$$



결론적으로 두 편차 벡터 사이의 각도가 상관계수를 결정

상관계수의 기하학적 해석

두 벡터 $\mathbf{x} = [x_1, x_2 \cdots, x_n]^T, \mathbf{y} = [y_1, y_2 \cdots, y_n]^T$ 를 생각해보자!



두 편차 벡터 d_x 와 d_y 에 대해 다음 식 성립



Remark

$$L_{d_i}^2 = d_i^T d_i = \sum_{j=1}^n (x_{ji} - \bar{x}_i)^2 = S_{x_i x_i}$$

$$\Rightarrow L_{d_x} = \sqrt{S_{x_i x_i}}$$

내적의 기하

θ 는 \mathbf{x} 와 \mathbf{y} 의 편차 벡터가 이루는 각도



$$S_{xy} = d_x^T d_y = \sqrt{S_{xx}} \sqrt{S_{yy}} \cos \theta$$

$$\therefore \cos \theta = \frac{S_{xy}}{\sqrt{S_{xx}} \sqrt{S_{yy}}} = r_{xy}$$




결론적으로 **두 편차 벡터 사이의 각도**가 상관계수를 결정




편차 벡터 사이의 각도는 어떤 의미인가?

상관계수의 기하학적 해석

두 벡터 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T, \mathbf{v} = [y_1, y_2, \dots, y_n]^T$ 를 생각해보자!



상관계수가 높은 x, y 의 plot



y 전체에 -10

$$T d_i = \sum_{j=1}^n (x_{ji} - \bar{x}_i)$$

$$\Rightarrow L_{d_x} = \sqrt{S_{x_i x_i}}$$



편차에는 영향을 주지 않고 평균에만 영향을 주며 **선형관계는 동일**

결국 편차 벡터의 **방향**이 유사하다는 것은 **함께 움직이는 정도**가 크다는 의미

$$\therefore \cos \theta = \frac{S_{xy}}{\sqrt{S_{xx}} \sqrt{S_{yy}}} = r_{xy}$$

“ 상관계수에 영향을 주는 것은 오직 편차가 함께 움직이는 정도 ”



4

고윳값과 고유벡터

고윳값과 고유벡터 *Eigen value & Eigen vector*

고유벡터

선형변환에 관계없이 공간을 유지하는 벡터





$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 의 열공간에서 $\begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix}$ 의 열공간으로 기저가 변환

초록색 벡터는 $\begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 7 \\ 2 \end{bmatrix}$ 로 변환

고윳값과 고유벡터 *Eigen value & Eigen vector*

고유벡터


선형변환에 관계없이 공간을 유지하는 벡터



기존에 초록색 벡터가 존재하던 열공간은 유지되지 않음

하지만 고유벡터는 변환 후에도 자신의 공간에 남아있음

고윳값과 고유벡터 *Eigen value & Eigen vector*



고유벡터 x 는 A 라는 선형변환을 가했음에도
벡터공간은 유지한 채 길이만 바뀜
이때 길이가 변하는 정도 : **고윳값 λ**

고윳값과 고유벡터 *Eigen value & Eigen vector*



고유벡터는 선형변환 시 **방향은 유지**한 채로
길이만 변하는, 영벡터가 아닌 벡터

고윳값은 고유벡터의 **길이**가 변하는 정도

고유벡터 x 는 A 라는 선형변환을 가했음에도
 벡터공간은 유지한 채 길이만 바뀜
 이때 길이가 변하는 정도 : **고윳값 λ**

따!~



고윳값과 고유벡터 *Eigen value & Eigen vector*

고윳값, 고유벡터 계산

$$Av = \lambda v$$

\vdots

v : 행렬 A 의 **고유벡터**

λ : 행렬 A 의 **고윳값**



$$Av = \lambda v$$

$$\Leftrightarrow (A - \lambda I)v = 0$$

행렬 $(A - \lambda I)$ 의 역행렬 존재 여부를 통해 고윳값과 고유벡터 계산!

고윳값과 고유벡터 *Eigen value & Eigen vector*

고윳값, 고유벡터 계산

$(A - \lambda I)$ 의 역행렬이 존재한다면?

\vdots

$$(A - \lambda I)^{-1}(A - \lambda I)v = 0$$

$$\Rightarrow v = 0$$

0은 어떤 변환을 가해도 0이기 때문에 고유벡터가 될 수 없음

\vdots

고유벡터가 존재한다면 $(A - \lambda I)$ 의 역행렬은 존재하지 않아야 함

$$\Leftrightarrow \det(A - \lambda I) = 0$$

고윳값과 고유벡터 *Eigen value & Eigen vector*

고윳값, 고유벡터 계산

$(A - \lambda I)$ 의 역행렬이 존재한다면?

\vdots

$$(A - \lambda I)^{-1}(A - \lambda I)v = 0$$

$$\Rightarrow v = 0$$

0은 어떤 변환을 가해도 0이기 때문에 고유벡터가 될 수 없음



고유벡터가 존재한다면 $(A - \lambda I)$ 의 역행렬은 존재하지 않아야 함

$$\Leftrightarrow \det(A - \lambda I) = 0$$

고윳값과 고유벡터 *Eigen value & Eigen vector*



고윳값 계산 예시



행렬식=0을 통해 고윳값 계산

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

$$\det(A - \lambda I) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix}$$

$$= (2 - \lambda)^2 - 1 = (\lambda - 1)(\lambda - 3) = 0$$

$$\lambda = 1 \text{ or } 3$$



고윳값과 고유벡터 *Eigen value & Eigen vector*



고유벡터 계산 예시



구한 λ 를 대입하여 고유벡터 계산

$$Av = \lambda v$$

$$\text{if } \lambda = 1,$$

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = 1 \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} \rightarrow \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\text{if } \lambda = 3,$$

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = 3 \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} \rightarrow \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$



고유공간 *Eigen space*

고유공간 *Eigen space*

각각의 고유벡터가 존재하는 공간

고유벡터 v 를 span하면 생김!

⋮



고유공간 내의 벡터는 모두 고유벡터

주로 사용하는 고유벡터 v 는 정규화로 길이를 1로 맞춤

아 하!



고윳값 분해 *Eigen Decomposition*

대각화 *Diagonalization*

$$D = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix}$$

대각행렬은 행렬식, 거듭제곱, 역행렬 계산 등에서 굉장히 편리



행렬 $A \in \mathbb{R}^{n \times n}$ 이 대각행렬 $D \in \mathbb{R}^{n \times n}$ 로 다음과 같이 대각화 가능하다면

행렬 A 의 행렬식, 거듭제곱 등을 쉽게 계산 가능

$$D = P^{-1}AP, P \in \mathbb{R}^{n \times n}$$

고윳값 분해 *Eigen Decomposition*

대각화 *Diagonalization*

$$D = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix}$$

대각행렬은 행렬식, 거듭제곱, 역행렬 계산 등에서 굉장히 편리



행렬 $A \in \mathbb{R}^{n \times n}$ 이 대각행렬 $D \in \mathbb{R}^{n \times n}$ 로 다음과 같이 대각화 가능하다면
 행렬 A 의 행렬식, 거듭제곱 등을 쉽게 계산 가능

$$D = P^{-1}AP, P \in \mathbb{R}^{n \times n}$$

고윳값 분해 *Eigen Decomposition*

행렬 A 가 $n \times n$ 정방행렬이라고 한다면,
 일반적으로 n 개의 고유벡터와 n 개의 고윳값 가짐
 \rightarrow 각각 고유벡터 v_1, \dots, v_n 이 $Av = \lambda v$ 을 만족!



$$\begin{aligned}
 Av &= \lambda v \\
 \Leftrightarrow A[v_1 \quad v_2 \quad \cdots \quad v_n] &= [\lambda_1 v_1 \quad \lambda_2 v_2 \quad \cdots \quad \lambda_n v_n] \\
 &= [v_1 \quad v_2 \quad \cdots \quad v_n] \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}
 \end{aligned}$$

고윳값 분해 *Eigen Decomposition*



양변에 고유벡터 행렬의 역행렬을 곱하면

$$A = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_n] \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_n]^{-1}$$

$$\Leftrightarrow A = V \Lambda V^{-1}$$

행렬 A 를 세 행렬의 곱으로 분해하는 것이 바로 **고윳값 분해**

V : 고유벡터들을 열벡터로 하는 행렬

Λ : 고윳값들을 대각원소로 하는 행렬

고윳값 분해 *Eigen Decomposition*

고윳값 분해를 통한 계산적 이점

행렬식

$$\begin{aligned}\det(A) &= \det(V\Lambda V^{-1}) \\ &= \cancel{\det(V)} \det(\Lambda) \cancel{\det(V^{-1})} \\ &= \det(\Lambda) = \lambda_1 \lambda_2 \cdots \lambda_n\end{aligned}$$

A 의 거듭제곱

$$\begin{aligned}A^k &= (V\Lambda V^{-1})^k \\ &= (V\Lambda V^{-1}) (V\Lambda V^{-1}) \cdots (V\Lambda V^{-1}) \\ &= V\Lambda^k V^{-1} = V \text{diag}(\lambda_1^k, \dots, \lambda_n^k) V^{-1}\end{aligned}$$

역행렬

$$\begin{aligned}A^{-1} &= (V\Lambda V^{-1})^{-1} \\ &= (V\Lambda^{-1}V^{-1}) \\ &= V \text{diag}(1/\lambda_1, \dots, 1/\lambda_n) V^{-1}\end{aligned}$$

대각합

$$\begin{aligned}\text{tr}(A) &= \text{tr}(V\Lambda V^{-1}) \\ &= \text{tr}(V^{-1}V\Lambda) = \text{tr}(\Lambda) = \sum_{i=1}^n \lambda_i\end{aligned}$$

고윳값 분해 *Eigen Decomposition*

고윳값 분해를 통한 계산적 이점

행렬식

$$\begin{aligned}\det(A) &= \det(V\Lambda V^{-1}) \\ &= \cancel{\det(V)} \det(\Lambda) \cancel{\det(V^{-1})} \\ &= \det(\Lambda) = \lambda_1 \lambda_2 \cdots \lambda_n\end{aligned}$$

A의 거듭제곱

$$\begin{aligned}A^k &= (V\Lambda V^{-1})^k \\ &= (V\Lambda V^{-1}) (V\Lambda V^{-1}) \cdots (V\Lambda V^{-1}) \\ &= V\Lambda^k V^{-1} = V \text{diag}(\lambda_1^k, \dots, \lambda_n^k) V^{-1}\end{aligned}$$

역행렬

$$\begin{aligned}A^{-1} &= (V\Lambda V^{-1})^{-1} \\ &= (V\Lambda^{-1}V^{-1}) \\ &= V \text{diag}(1/\lambda_1, \dots, 1/\lambda_n) V^{-1}\end{aligned}$$

대각합

$$\begin{aligned}\text{tr}(A) &= \text{tr}(V\Lambda V^{-1}) \\ &= \text{tr}(V^{-1}V\Lambda) = \text{tr}(\Lambda) = \sum_{i=1}^n \lambda_i\end{aligned}$$

고윳값 분해 *Eigen Decomposition*

고윳값 분해를 통한 계산적 이점

행렬식

$$\begin{aligned}\det(A) &= \det(V\Lambda V^{-1}) \\ &= \cancel{\det(V)} \det(\Lambda) \cancel{\det(V^{-1})} \\ &= \det(\Lambda) = \lambda_1 \lambda_2 \cdots \lambda_n\end{aligned}$$

A의 거듭제곱

$$\begin{aligned}A^k &= (V\Lambda V^{-1})^k \\ &= (V\Lambda V^{-1}) (V\Lambda V^{-1}) \cdots (V\Lambda V^{-1}) \\ &= V\Lambda^k V^{-1} = V \text{diag}(\lambda_1^k, \dots, \lambda_n^k) V^{-1}\end{aligned}$$

역행렬

$$\begin{aligned}A^{-1} &= (V\Lambda V^{-1})^{-1} \\ &= (V\Lambda^{-1}V^{-1}) \\ &= V \text{diag}(1/\lambda_1, \dots, 1/\lambda_n) V^{-1}\end{aligned}$$

대각합

$$\begin{aligned}\text{tr}(A) &= \text{tr}(V\Lambda V^{-1}) \\ &= \text{tr}(V^{-1}V\Lambda) = \text{tr}(\Lambda) = \sum_{i=1}^n \lambda_i\end{aligned}$$

고윳값 분해 *Eigen Decomposition*

고윳값 분해를 통한 계산적 이점

행렬식

$$\begin{aligned}\det(A) &= \det(V\Lambda V^{-1}) \\ &= \cancel{\det(V)} \det(\Lambda) \cancel{\det(V^{-1})} \\ &= \det(\Lambda) = \lambda_1 \lambda_2 \cdots \lambda_n\end{aligned}$$

A의 거듭제곱

$$\begin{aligned}A^k &= (V\Lambda V^{-1})^k \\ &= (V\Lambda V^{-1}) (V\Lambda V^{-1}) \cdots (V\Lambda V^{-1}) \\ &= V\Lambda^k V^{-1} = V \text{diag}(\lambda_1^k, \dots, \lambda_n^k) V^{-1}\end{aligned}$$

역행렬


$$\begin{aligned}A^{-1} &= (V\Lambda V^{-1})^{-1} \\ &= (V\Lambda^{-1}V^{-1}) \\ &= V \text{diag}(1/\lambda_1, \dots, 1/\lambda_n) V^{-1}\end{aligned}$$

대각합

$$\begin{aligned}\text{tr}(A) &= \text{tr}(V\Lambda V^{-1}) \\ &= \text{tr}(V^{-1}V\Lambda) = \text{tr}(\Lambda) = \sum_{i=1}^n \lambda_i\end{aligned}$$

고윳값 분해 *Eigen Decomposition*


기하학적 의미



- A 는 $n \times n$ 선형변환이므로
차원이 유지됨
- A 의 고유벡터인 p_1, p_2 는 변환 이후에도
공간이 유지됨
- P 와 P^{-1} 은 직교행렬이므로 공간을 회전시킴
- 고윳값 λ 는 고유벡터의 방향으로 스케일링
- 고윳값 분해란? A 변환을
회전 \rightarrow 스케일링 \rightarrow 회전으로 분해한 것!

고윳값 분해 *Eigen Decomposition*



기하학적 의미



- A 는 $n \times n$ 선형변환이므로
차원이 유지됨
- A 의 고유벡터인 p_1, p_2 는 변환 이후에도
공간이 유지됨
- P 와 P^{-1} 은 직교행렬이므로 공간을 회전시킴
- 고윳값 λ 만큼 고유벡터의 방향으로 스케일링
- 고윳값 분해란? A 변환을
회전 \rightarrow 스케일링 \rightarrow 회전으로 분해한 것!

고윳값 분해 *Eigen Decomposition*

기하학적 의미



- A 는 $n \times n$ 선형변환이므로
차원이 유지됨
- A 의 고유벡터인 p_1, p_2 는 변환 이후에도
공간이 유지됨
- P 와 P^{-1} 은 직교행렬이므로 공간을 회전시킴
- 고윳값 λ 는 고유벡터의 방향으로 스케일링
- 고윳값 분해란? A 변환을
회전 \rightarrow 스케일링 \rightarrow 회전으로 분해한 것!

고윳값 분해의 조건

A가 (고윳값 분해) 대각화 가능



$V^{-1}AV = \Lambda$ 인 V가 존재



V가 역행렬이 존재

A가 **n개의 선형독립인** 고유벡터를 가짐
→ 고유벡터행렬 **V가 선형독립**

대각화 가능한 행렬: Diagonalizable Matrix

대각화 불가능한 행렬: Defective Matrix

고윳값 분해의 조건

A가 (고윳값 분해) 대각화 가능



$V^{-1}AV = \Lambda$ 인 V 가 존재



V 가 역행렬이 존재

A가 **n개의 선형독립인** 고유벡터를 가짐
→ 고유벡터행렬 **V가 선형독립**

대각화 가능한 행렬: Diagonalizable Matrix

대각화 불가능한 행렬: Defective Matrix

대칭 행렬과 고윳값 분해



실수인 대칭행렬의 성질

- ① 모든 고윳값이 실수
- ② 항상 대각화 (고윳값 분해) 가능
- ③ 고유벡터들이 서로 직교

(Proof ③)

$$Av_i = \lambda_i v_i, Av_j = \lambda_j v_j \quad (i \neq j)$$

$$\begin{aligned} \lambda_i (v_i \cdot v_j) &= v_j^T \lambda_i v_i = v_j^T Av_i = (v_j^T Av_i)^T \\ &= v_i^T Av_j = v_i^T \lambda_j v_j = \lambda_j v_i^T v_j = \lambda_j (v_i \cdot v_j) \end{aligned}$$

내적이 0이어야 식이 성립!



대칭 행렬과 고윳값 분해

실수 대칭행렬에는 무엇이 있을까?

① 모든 고윳값이 실수

② 항상 대칭행렬 고윳값 분해 가능

$$Cov(X, X) = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) & \cdots & Cov(X_1, X_n) \\ Cov(X_2, X_1) & Var(X_2) & \cdots & Cov(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(X_n, X_1) & Cov(X_n, X_2) & \cdots & Var(X_n) \end{bmatrix}$$

공분산 행렬 $Cov(X, X)$ ⇒ 고유벡터들이 서로 직교

(Proof ③)

→ 고윳값 분해를 공분산 행렬에 적용한 것이 PCA

$$\begin{aligned} \lambda_i(v_i \cdot v_j) &= v_j^T \lambda_i v_i = v_j^T A v_i = (v_j^T A v_i)^T \text{클린업 3주차에 등장 예정!} \\ &= v_i^T A v_j = v_i^T \lambda_j v_j = \lambda_j v_i^T v_j = \lambda_j(v_i \cdot v_j) \end{aligned}$$

5

특잇값 분해(SVD)

특잇값 분해

특잇값 분해 *Singular Value Decomposition*

직교하는 벡터 집합에 대하여 선형변환 후에
크기는 변하지만 여전히 직교하는 직교집합을 찾는 것

$$A = U\Sigma V^T$$





특잇값 분해

특잇값 분해 *Singular Value Decomposition*

특잇값 분해의 아이디어

직교하는 벡터 집합에 대하여 선형변환 후에


크기는 변하지만 여전히 직교하는 직교집합을 찾는 것

직사각 행렬은 고윳값 분해가 불가능


→ $A^T A, A A^T$ 는 대칭행렬이 되므로 이를 이용

$$A = U \Sigma V^T!$$

SVD는 고윳값 분해의 일반화



특잇값 분해



$m - n$ 만큼 전부 0

직사각 행렬 A

= 직교 행렬 $U \times$ 대각 직사각 행렬 $\Sigma \times$ 직교 행렬 V^T



특잇값 분해



특잇값이란?

$$\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \text{의 } \sigma_i \text{들을 } A \text{의 특잇값(Singular Value)이라고 함}$$

Diagram illustrating the SVD decomposition of matrix A (size $m \times n$) into three matrices: U (size $m \times m$), Σ (size $m \times n$), and V^T (size $n \times n$). The matrix Σ is shown with diagonal elements $\sigma_1, \dots, \sigma_n$ and zeros elsewhere. The matrices are connected by multiplication signs (\times).

σ_i 는 AA^T 나 $A^T A$ 를 고유값 분해해서 나오는 고유값의 제곱근
직사각 행렬 A

$$= \text{직교 행렬 } U \times \text{대각 직사각 행렬 } \Sigma \times \text{직교 행렬 } V^T$$



특잇값 분해

U 도출하기

$$\begin{aligned} AA^T &= (U\Sigma V^T)(U\Sigma V^T)^T = (U\Sigma V^T)(V\Sigma^T U^T) \\ &= U\Sigma^T U^T = U\Lambda U^T \end{aligned}$$

Then, $U \in \mathbb{R}^{m \times m}$ ($\because AA^T \in \mathbb{R}^{m \times m}$)

실수 대칭행렬 $\rightarrow U$ 직교행렬

V^T 도출하기

$$\begin{aligned} A^T A &= (U\Sigma V^T)^T (U\Sigma V^T) = (V\Sigma^T U^T)(U\Sigma V^T) \\ &= V\Sigma^2 V^T = V\Lambda V^T \end{aligned}$$

Then, $V^T \in \mathbb{R}^{m \times m}$ ($\because A^T A \in \mathbb{R}^{m \times m}$)

특잇값 분해

U 도출하기

$$\begin{aligned} AA^T &= (U\Sigma V^T)(U\Sigma V^T)^T = (U\Sigma V^T)(V\Sigma^T U^T) \\ &= U\Sigma^T U^T = U\Lambda U^T \end{aligned}$$

Then, $U \in \mathbb{R}^{m \times m}$ ($\because AA^T \in \mathbb{R}^{m \times m}$)

V^T 도출하기

실수 대칭행렬 $\rightarrow V^T$ 직교행렬

$$\begin{aligned} A^T A &= (U\Sigma V^T)^T (U\Sigma V^T) = (V\Sigma^T U^T)(U\Sigma V^T) \\ &= V\Sigma^2 V^T = V\Lambda V^T \end{aligned}$$

Then, $V^T \in \mathbb{R}^{m \times m}$ ($\because A^T A \in \mathbb{R}^{m \times m}$)



특잇값 분해의 이해

특잇값 분해 *Singular Value Decomposition*


앞서, 직교하는 벡터 집합에 대하여 선형변환 후에
크기는 변하지만 **여전히 직교**하는 직교집합을 찾는 것이라고 했음

$$A = U\Sigma V^T$$

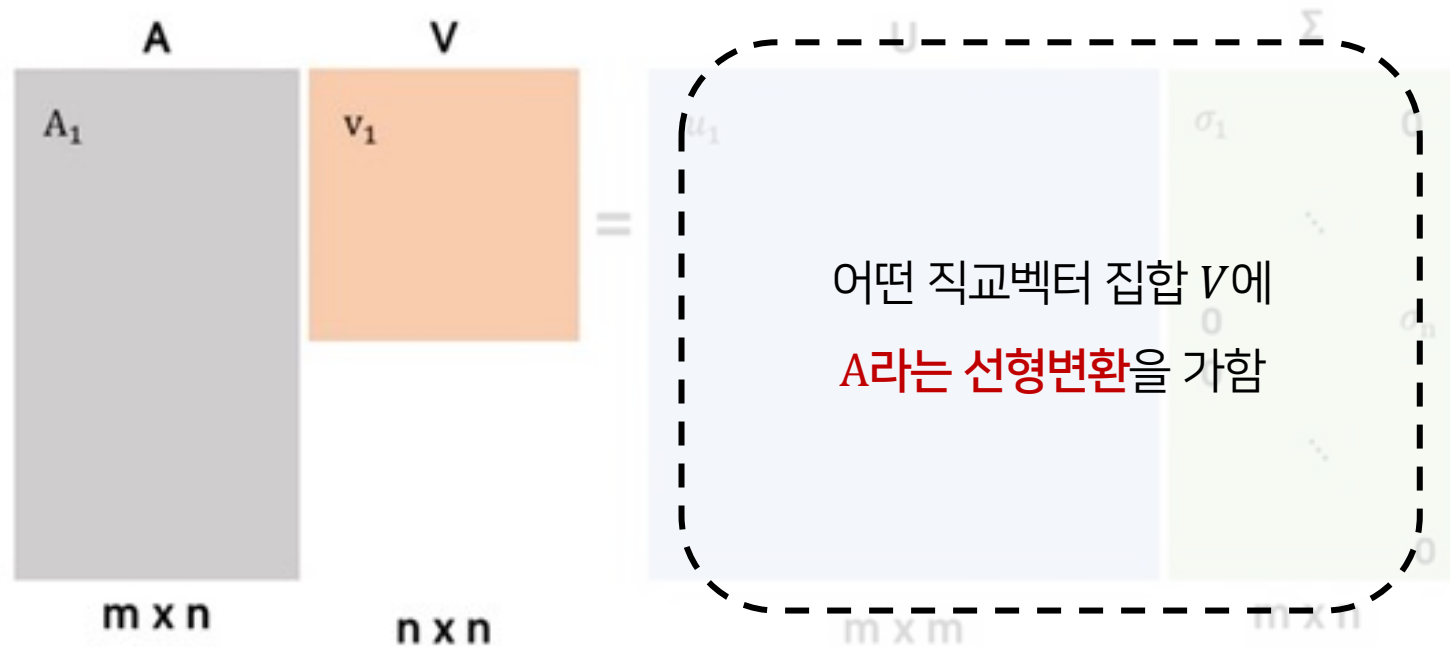


$$AV = U\Sigma$$


이해하기 쉽게 식을 변형하여 분석



특잇값 분해의 이해



특잇값 분해의 이해



이때, 스케일링을 위해 Σ 를 사용

특잇값 분해의 이해



직사각행렬 A 에 대해서 선형변환을 했을 때,
벡터공간을 유지하는 공통의 벡터를 찾는 것(EVD)은 **불가능**

어떤 직교벡터 집합 U 에
 특잇값을 곱함




A 로 선형변환 이후에도
직교성만은 유지(SVD)하는 벡터 집합을 찾자!

스케일링을 위해 Σ 를 사용



특잇값 분해의 기하학적 의미



• 행렬 A 는 2×3 변환이므로 차원이 변화함


• V^T 와 U 는 벡터공간을 회전시킴

• Σ 는 벡터공간을 스케일링 + 차원변화

• 특잇값 분해란? A 변환을

회전 \rightarrow 스케일링 + 차원변화 \rightarrow 회전으로 분해!

특잇값 분해의 기하학적 의미



• 행렬 A 는 2×3 변환이므로 차원이 변화함


• V^T 와 U 는 벡터공간을 회전시킴

• Σ 는 벡터공간을 스케일링 + 차원변화

• 특잇값 분해란? A 변환을

회전 \rightarrow 스케일링 + 차원변화 \rightarrow 회전으로 분해!

특잇값 분해의 기하학적 의미



• 행렬 A 는 2×3 변환이므로 차원이 변화함

• V^T 와 U 는 벡터공간을 회전시킴

• Σ 는 벡터공간을 스케일링 + 차원변화

• 특잇값 분해란? A 변환을

회전 \rightarrow 스케일링 + 차원변화 \rightarrow 회전으로 분해!

특잇값 분해의 이점

$$A = U\Sigma V^T$$

$$= \begin{bmatrix} | & & | \\ u_1 & \cdots & u_m \\ | & & | \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_m \end{bmatrix} \begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_n^T & - \end{bmatrix}$$

$$= \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T \cdots = \sum_{i=1}^n \sigma_i u_i v_i^T$$



$$\dim(\sigma_i u_i v_i^T) = \dim(A)$$

→ 행렬 A를 정보량 σ_i 에 따라 여러 개의 layer로 쪼갤 수 있음

특잇값 분해의 응용

Reduced SVD

기존 SVD는 비어 있는 열이 많아 비효율적
→ 여러 방법론으로 **빈 공간을 제거**하면 **효율적인 연산**이 가능

Reduced SVD	---	Thin SVD	Σ 의 비어있는 행들을 제거
	---	Compact SVD	특잇값이 0인 부분도 제거
	---	Truncated SVD	상위 t 개 특잇값만 사용



특잇값 분해의 응용

Reduced SVD

기존 SVD는 비어 있는 열이 많아 비효율적
 → 여러 방법론으로 **빈 공간을 제거**하면 **효율적인 연산**이 가능

Reduced SVD	--- Thin SVD	Σ 의 비어있는 행들을 제거
	--- Compact SVD	특잇값이 0인 부분도 제거
	--- Truncated SVD	상위 t 개 특잇값만 사용



특잇값 분해의 응용

Full SVD

기존의 SVD로, **정보가 비어 있는 부분**이 다수 존재

$$\boxed{A} = \boxed{U} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_s \\ & & & 0 \end{bmatrix} \boxed{V^T}$$

→ 0인 부분 모두 연산하므로 **연산량 낭비**

특잇값 분해의 응용

Thin SVD

Σ 의 하단의 비어 있는 **비대각 부분**과 이에 **대응하는 U의 열**을 제거

$$A = U_s \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_s \\ & & & 0 & \dots \end{bmatrix} V^T$$

→ 0이었던 부분이 삭제되므로 A 복원 가능

특잇값 분해의 응용

Compact SVD

Thin SVD에 더해 Σ 중 σ_i 가 0인 열과 이에 대응하는 U 의 열을 제거

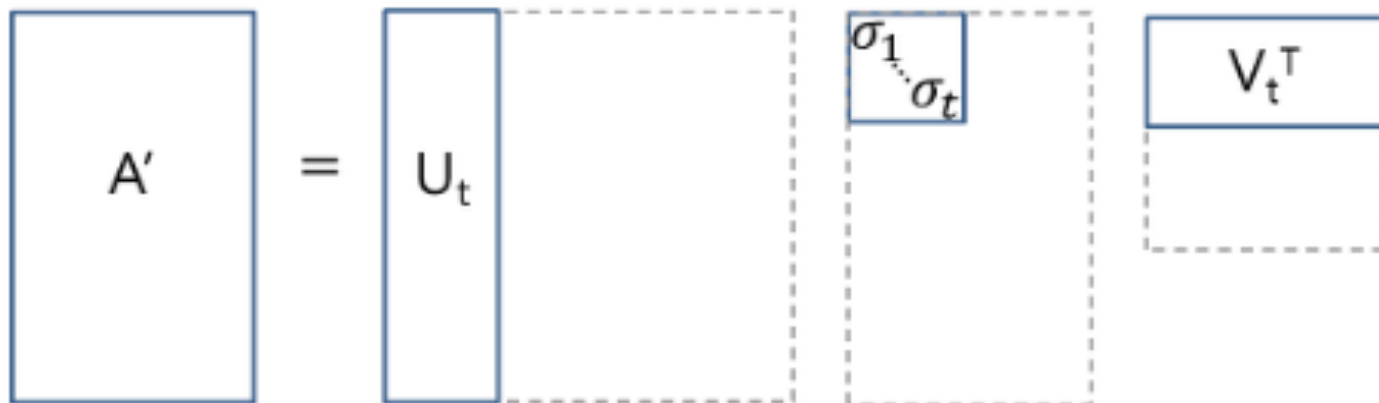
$$A = U_r \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} V_r^T$$

→ 정보량이 있는 (특잇값이 양수) 열만 남기고 제거

특잇값 분해의 응용

Truncated SVD

Σ 의 상위 t 개 σ_i 만 골라 이에 대응하는 U 의 열을 제거



The diagram illustrates the Truncated SVD equation $A' = U_t \Sigma_t V_t^T$. On the left is a solid blue rectangle labeled A' . To its right is an equals sign. Next is a solid blue rectangle labeled U_t . This is followed by a large dashed rectangle representing the diagonal matrix Σ . Inside the top-left corner of this dashed rectangle is a smaller solid blue rectangle labeled $\sigma_1 \dots \sigma_t$, representing the truncated singular values. To the right of the dashed rectangle is another solid blue rectangle labeled V_t^T . The entire right-hand side of the equation is enclosed in a larger dashed rectangle.

→ 온전한 복원이 아닌 데이터의 정보를 압축하여 A 를 근사

Truncated SVD

선택한 **특잇값의 개수에 따라** 복원 행렬의 원본 행렬 **복원도**가 달라짐



$$\sum_{i=1}^{n=20} \sigma_i u_i v_i^T$$



$$\sum_{i=1}^{n=100} \sigma_i u_i v_i^T$$



$$\sum_{i=1}^{n=512} \sigma_i u_i v_i^T$$

Truncated SVD

원본



THANK YOU

세미나입니다. 자중해주세요

죄송합니다... 잘못 보냈습니다..